

Proiect 5 — Detectarea campaniilor coordonate: clusterizare semantică și analiză temporală (bursts)

1. Descriere

Proiectul urmărește identificarea campaniilor coordonate într-un flux de texte (postări, comentarii, știri) prin combinarea similarității semantice cu analiza temporală. Spre deosebire de deduplicarea exactă, abordarea bazată pe embeddings permite gruparea mesajelor care transmit același conținut în formulări diferite [1]. Pentru componenta temporală, modelul clasic de detectare a „burst”-urilor oferă un cadru formal pentru identificarea intensificărilor de activitate în timp [2].

2. Resurse necesare și surse de date (download)

Corpus text: (i) știri românești (RoLargeSum) ca sursă de text; (ii) date cu timestamp (colectare controlată) pentru scenarii sociale [3].

Pentru evaluare: set de studii de caz (evenimente) + validare manuală a clusterelor suspecte. În lipsa ground truth, se recomandă evaluare intrinsecă (coeziune cluster) și evaluare expert (interpretabilitate).

3. Metodă

- 3.1. Embeddings: se encodează fiecare mesaj cu Sentence-BERT (sau variantă multilinguală) [1].
- 3.2. Căutare vecini: se indexează vectorii cu FAISS pentru căutare rapidă la scară [4].
- 3.3. Clustering: HDBSCAN este adecvat pentru densități diferite și pentru a evita alegerea manuală a lui K [5].
- 3.4. Analiză temporală: pentru fiecare cluster se construiește o serie temporală; se calculează scor de burst (Kleinberg) și măsuri de concentrare temporală [2].
- 3.5. Raportare: se extrag exemple reprezentative și se explică scorul (similaritate + sincronizare).

4. Evaluare

- 4.1. Coeziune cluster: densitate, silhouette (unde e aplicabil), consistență semantică.
- 4.2. Coordonare temporală: scor de burst și stabilitate pe ferestre diferite.
- 4.3. Ablații: TF-IDF vs embeddings; KMeans vs HDBSCAN; cu/ fără burst scoring.

5. Tehnologii

- 5.1. Sentence-transformers; FAISS; HDBSCAN; pandas; Plotly/Streamlit pentru vizualizare [6].

6. Livrabile

- 6.1. Pipeline embedding→index→clustering→burst.
- 6.2. Dashboard: clustere + timeline + scoruri.
- 6.3. Raport: top campanii cu evidențe (mesaje, perioade, explicații).

Bibliografie

- 1. Reimers, N., & Gurevych, I. (2019). Sentence-BERT. arXiv. Link: <https://arxiv.org/abs/1908.10084>
- 2. Kleinberg, J. (2003). Bursty and Hierarchical Structure in Streams. Cornell. Link: <https://www.cs.cornell.edu/home/kleinber/bhs.pdf>
- 3. Avram, A. M. et al. RoLargeSum dataset (repo). Link: <https://github.com/avramandrei/rolargesum>
- 4. FAISS (Meta AI) repository. Link: <https://github.com/facebookresearch/faiss>
- 5. HDBSCAN library repository. Link: <https://github.com/scikit-learn-contrib/hdbscan>
- 6. Streamlit Documentation. Link: <https://docs.streamlit.io/>